

TCC029010 - Trabalho de Conclusão de Curso

Detecção de nódulos em imagens mamográficas utilizando aprendizado profundo e Transformada Wavelet

Jéssica Gomes Carrico

Orientador Ramon Mayor Martins

Coorientadora Elen Macedo Lobato

Engenharia de Telecomunicações
Instituto Federal de Santa Catarina
campus São José

11 de dezembro de 2025



Motivação

- O câncer de mama permanece entre as principais causas de mortalidade em mulheres.
- A detecção precoce é fundamental para aumentar as chances de tratamento eficaz.
- A interpretação visual de mamografias pode ser subjetiva e suscetível a erros, como falsos positivos e falsos negativos.
- Ferramentas computacionais, especialmente redes neurais convolucionais (*CNNs*), podem apoiar a análise de imagens, contribuindo para:
 - maior precisão diagnóstica;
 - redução de procedimentos desnecessários.



Objetivo Geral

Desenvolver e comparar algoritmo para detecção automática de nódulos em mamografias, utilizando a decomposição Wavelet como pré-processamento e diferentes arquiteturas de CNNs (treinadas do zero e com Transfer Learning). Além disso, avaliar se *Wavelet* e *data augmentation* melhoram a precisão diagnóstica.



Objetivos

Objetivos Específicos

- 1 Selecionar e analisar imagens de mamografia da base pública *Mini-MIAS*.
- 2 Implementar a decomposição *Wavelet* para destacar padrões relevantes e reduzir ruídos.
- 3 Aplicar *data augmentation* (transformações geométricas e fotométricas) para aumentar a variabilidade das imagens.
- 4 Treinar modelos de CNN, incluindo redes simples treinadas do zero e arquiteturas ResNet-18/34/50 com *Transfer Learning*.
- 5 Avaliar os modelos em diferentes cenários (com/sem Wavelet e com/sem augmentation), usando acurácia, precisão, recall e F1-score.
- 6 Comparar os resultados para analisar o impacto das estratégias de pré-processamento e aumento de dados.



Fundamentação Teórica — Câncer de Mama

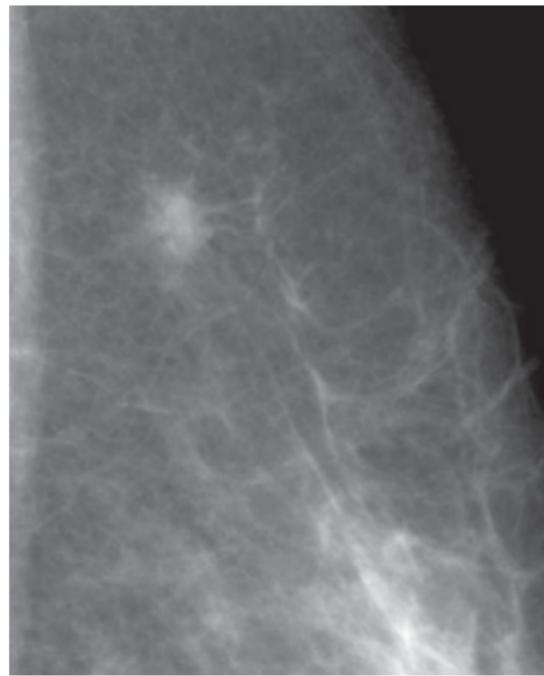
- Desenvolve-se a partir de alterações celulares nos lóbulos ou ductos.
- Principais alterações:
 - Hiperplasia
 - Hiperplasia atípica
 - Carcinoma *in situ*
 - Carcinoma invasivo
- Sinais clínicos: pele em “casca de laranja” e linfonodos axilares aumentados.
- Fatores de risco: genéticos, hormonais e relacionados ao estilo de vida.
- Detecção geralmente realizada por exames de imagem, como a mamografia.



- Técnica de diagnóstico por imagem utilizada para a detecção precoce do câncer de mama.
- Diferenças em relação à mamografia convencional:
 - Substitui filmes radiográficos por detectores eletrônicos, convertendo a radiação em sinais digitais.
 - Permite ajustes como contraste, brilho e ampliação da imagem.

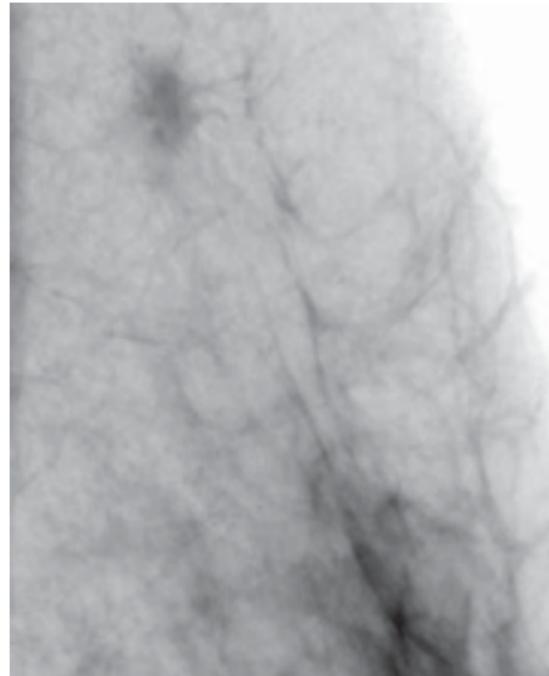


Fundamentação Teórica – Mamografia Digital – Exemplo



(a) Ampliação

Fonte: Freitas et al., 2006



(b) Ampliação e inversão de contraste



■ Mama:

- Tecido gorduroso (mais claro na imagem).
- Tecido fibroglandular (mais escuro na imagem).
- Existe variação natural na densidade do tecido mamário entre mulheres.

■ Densidade Mamária – Sistema BI-RADS:

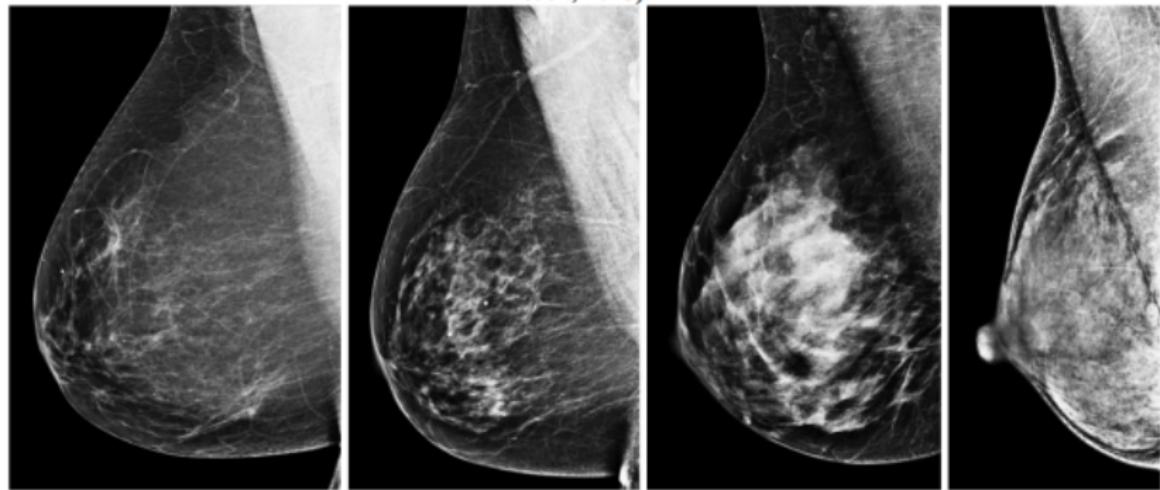
- Classificação padronizada da densidade mamária:

Categoría	Descrição
A	Mama quase totalmente gordurosa
B	Áreas dispersas de tecido fibroglandular
C	Mama heterogeneamente densa
D	Mama extremamente densa

Mamas densas (C e D) dificultam a visualização de nódulos → desafio diagnóstico.



Fundamentação Teórica – Densidade Mamária – Exemplo



Classificação visual das densidades mamárias segundo o sistema BI-RADS

Fonte: Sousa, 2017.

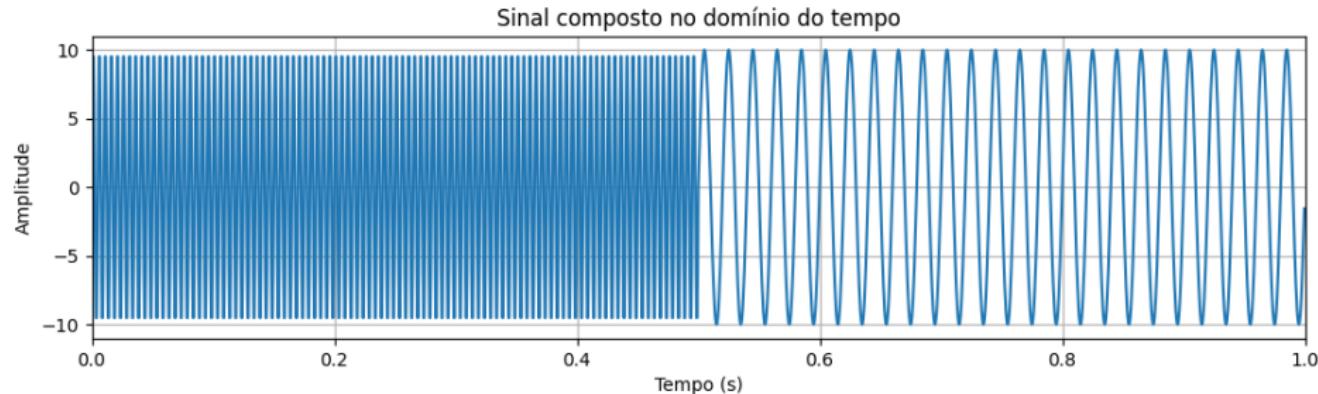


Fundamentação Teórica — Transformada Wavelet

- A Transformada Wavelet resolve uma limitação da Transformada de Fourier: a falta de localização temporal (espacial) das frequências.
- Em vez de senóides, utiliza funções *wavelet*, que são localizadas no tempo (**translação**) e na escala (**dilatação**).
- A **Transformada Wavelet Contínua (CWT)** permite observar quando e quais frequências ocorrem.
- A **Transformada Wavelet Discreta (DWT)** discretiza os parâmetros e viabiliza implementação computacional.
- São usados **bancos de filtros (FWT)** para decompor o sinal em **aproximação** (baixa frequência) e **detalhe** (alta frequência).
- Também é aplicada para **remoção de ruído (denoising)** com técnicas de limiarização.



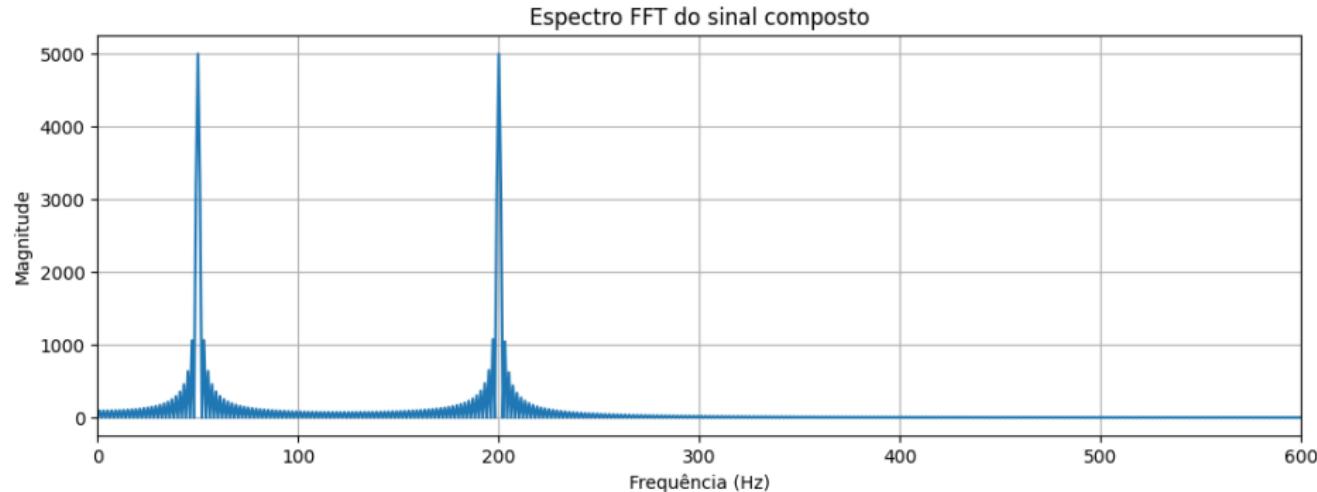
Fundamentação Teórica — Sinal no Tempo



Fonte: Elaborado pela autora.



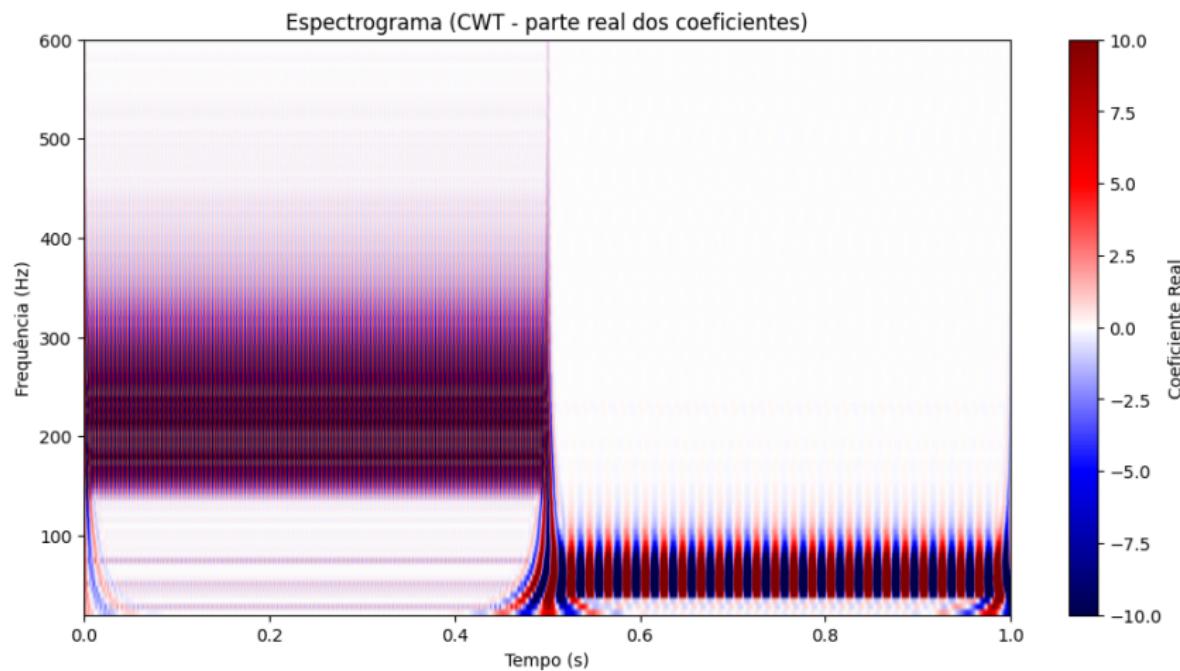
Fundamentação Teórica — Transformada de Fourier



Fonte: Elaborado pela autora.



Fundamentação Teórica — Transformada Wavelet

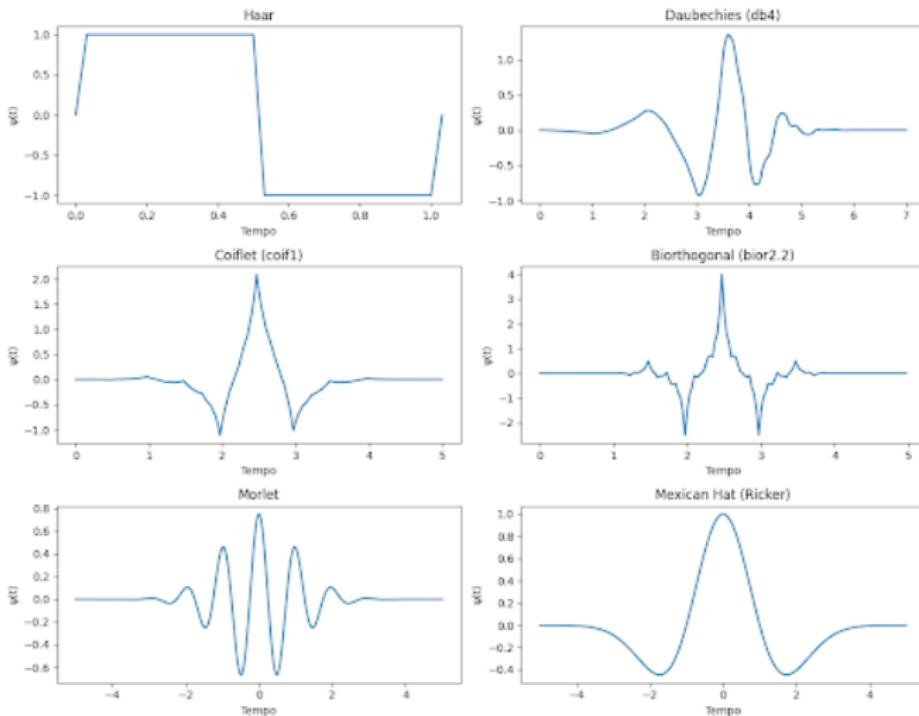


Fonte: Elaborado pela autora.



Fundamentação Teórica — Famílias de Wavelets

Funções Wavelet Mãe



Fonte: Elaborado pela autora.

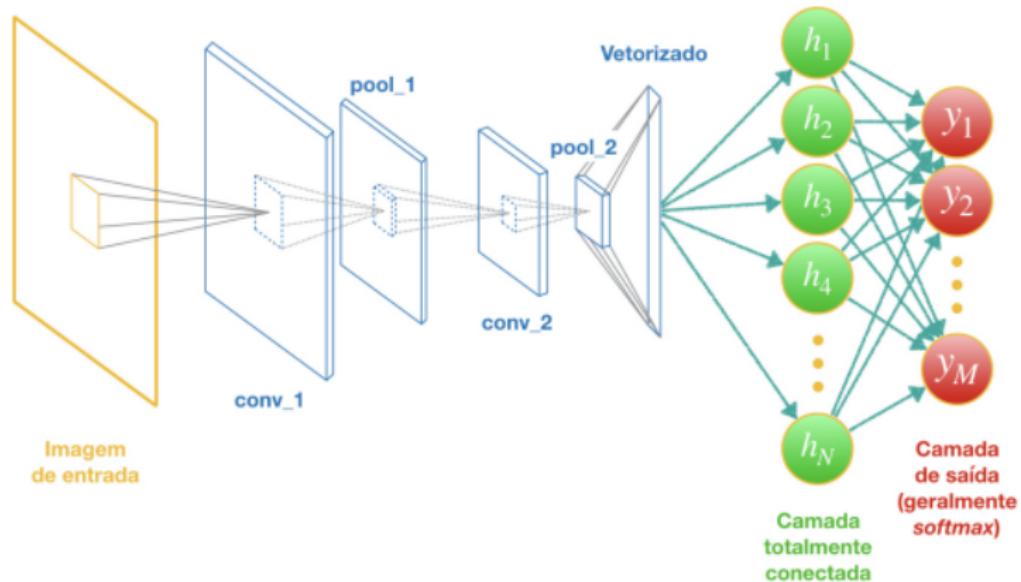


Fundamentação Teórica — Redes Neurais Convolucionais (CNNs)

- Arquitetura composta por: camadas convolucionais, *pooling* e camadas totalmente conectadas.
- Ideal para extração de padrões em imagens.
- Camadas convolucionais geram *feature maps*.
- Pooling reduz a dimensionalidade e elimina ruído.
- Camadas totalmente conectadas integram as características.
- O *Transfer Learning* reutiliza modelos pré-treinados em novos conjuntos de dados.



Fundamentação Teórica — Arquitetura de uma Rede Neural Convolucional



Fonte: Silva Junior, 2022.



Fundamentação Teórica — Operações em CNNs: Convolução e Pooling

0	1	1	1	0	0	0	0
0	0	1	1	1	0	0	0
0	0	0	1	1	1	1	0
0	0	0	1	1	0	0	0
0	0	1	1	0	0	0	0
0	1	1	0	0	0	0	0
1	1	0	0	0	0	0	0

I

1	0	1
0	1	0
1	0	1

K

1	4	3	4	1
1	2	4	3	3
1	2	3	4	1
1	3	3	1	1
3	3	1	1	0

I * K

Convolução

12	20	37	4
8	12	25	12
30	0	70	34
0	6	112	100



13	20
9	79

Average-pooling

20	37
30	112

Max-pooling

Pooling

Fonte: Rosa, 2025.



- Abordagem baseada em Aprendizado de Máquina Centrado no Ser Humano (HCML).
- Desenvolvimento iterativo: análise de requisitos até previsão final.
- Pesquisa quantitativa aplicada, tipo quase-experimento tecnológico.
- Utilização de dados secundários (imagens prontas) para análise.



Etapas do processo de Aprendizado de Máquina Centrado no Ser Humano (HCML)



Fonte: Martins et al., 2024.

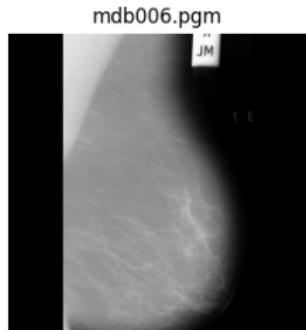
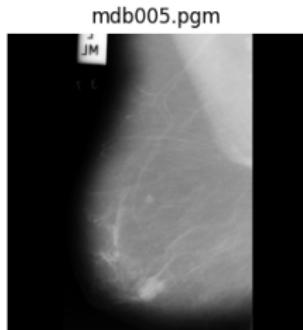
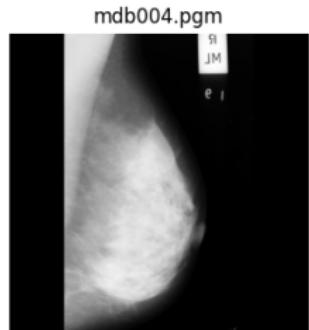
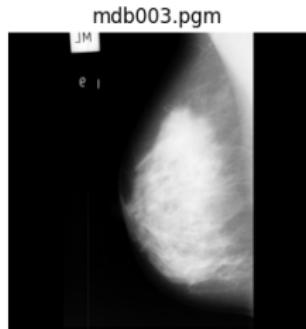
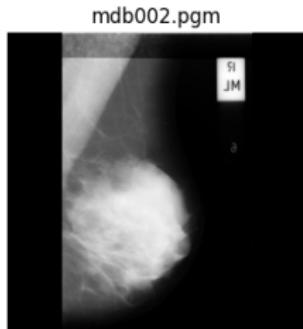
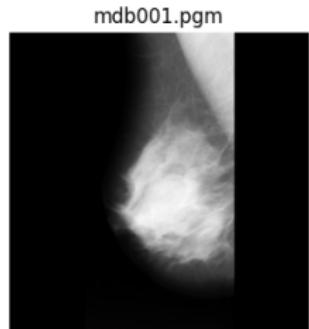


Metodologia – Coleta de Dados

- Base utilizada: Mini-MIAS — 322 imagens mamográficas digitais.
- Imagens em formato PGM, resolução 1024×1024 pixels.
- Anotações clínicas feitas por radiologistas: presença, tipo e localização das anomalias.
- Densidade mamária classificada em F, G, D.
- Tipos de anormalidade: calcificações, massas, distorções, assimetrias, normais.
- Etiquetas indicam também benignidade (B) ou malignidade (M).



Metodologia – Amostra da Base Mini-MIAS



Fonte: <https://www.kaggle.com/datasets/kmader/mias-mammography>



Metodologia – Etapas do Experimento

- Os experimentos foram estruturados em três etapas principais:
 - **Definição da arquitetura:** CNN simples (2 convoluções + *pooling*) e modelos pré-treinados ResNet-18, ResNet-34 e ResNet-50.
 - **Combinações de tratamento:** *Baseline*, *Data Augmentation*, *Wavelet (Coiflet, Daubechies, Symlet)* e *Wavelet (Coiflet, Daubechies, Symlet) + Augmentation*.
 - **Avaliação padronizada:** Acurácia, Precisão, *Recall*, *F1-score* e análise dos resultados.

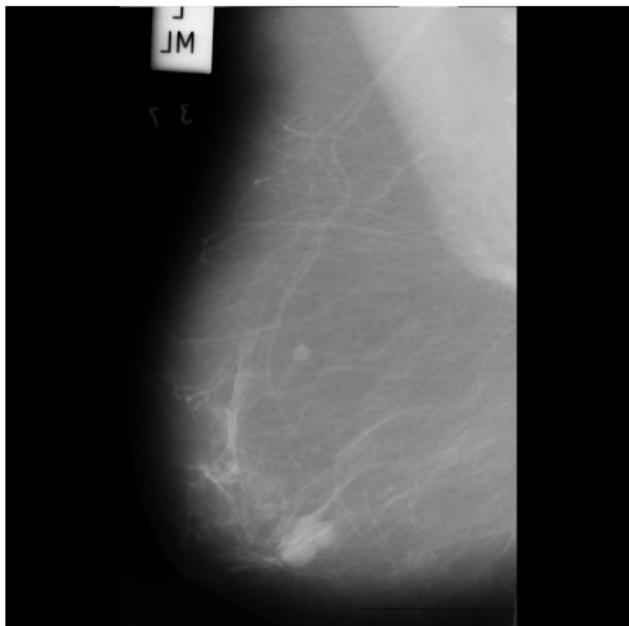


Metodologia – Pré-processamento das Imagens

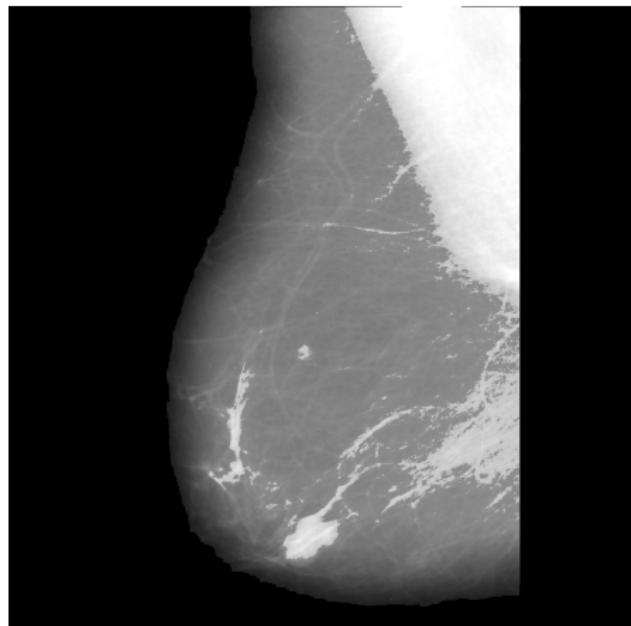
- **Segmentação da Região da Mama:** realizada em cinco passos: binarização inicial, remoção de ruídos por operações morfológicas, identificação das componentes conectadas, seleção da maior região (tecido mamário) e aplicação da máscara final.
- **Realce de Pixels Claros:** limiarização fixa (pixel 145) para destacar regiões densas e de potencial interesse radiológico.
- **Denoising por Wavelets:** transformada 2D com *hard threshold* e limiar baseado no desvio padrão estimado, nas áreas realçadas.
- **Ajuste de Brilho Local:** incremento de $\approx 35\%$ aplicado somente nas regiões claras segmentadas.



Exemplo de Pré-processamento: Antes e Depois



(a) Imagem Original



(b) Imagem Pré-processada

Fonte: Elaborada pela autora.



Metodologia – Data Augmentation

- Para aumentar a diversidade do conjunto de treinamento e reduzir *overfitting*, foram aplicadas transformações aleatórias apenas nas imagens de treino.
- Operações utilizadas:
 - Reflexão horizontal e vertical (probabilidade de 50%);
 - Rotação aleatória no intervalo de -15° a $+15^\circ$.
- No conjunto de teste, não foram aplicadas transformações aleatórias, apenas a normalização padrão.



Metodologia – Procedimentos de Treinamento e Teste

- O conjunto foi dividido em **80% treino** e **20% teste**, mantendo a mesma proporção em todos os experimentos.
- **Balanceamento do treino:** devido ao desbalanceamento entre Normal e Anormal, utilizou-se um amostrador aleatório ponderado, atribuindo pesos inversamente proporcionais à frequência das classes.
- **Configuração dos DataLoaders:**
 - Batch size: 16;
 - Sampler balanceado apenas no treino;
 - Teste sem embaralhamento para garantir reproduzibilidade.
- **Treinamento:** todas as arquiteturas foram treinadas nas mesmas condições:
 - Otimizador Adam ($\text{lr} = 0,001$);
 - Função de perda *CrossEntropyLoss*;
 - 30 épocas.



- A implementação foi realizada em **Python 3.8+**, utilizando:
 - **PyTorch 2.0** para construção e treinamento das redes neurais;
 - **PyWavelets 1.4.1** para a decomposição wavelet multinível.
- A reproduzibilidade foi garantida pela disponibilização do código em repositório público no GitHub, permitindo a replicação dos experimentos.
- **Ambiente de execução:** Google Colaboratory.
- Quando disponível, foi utilizada uma **GPU NVIDIA Tesla T4 (16 GB VRAM)** para acelerar o treinamento.



Resultados – CNN Simples

Arq.	Config.	Acc	P(N)	R(N)	F1(N)	P(A)	R(A)	F1(A)
CNN Simples	Baseline	0,5152	0,61	0,67	0,64	0,30	0,25	0,27
CNN Simples	+ Augmentation	0,5000	0,65	0,48	0,55	0,37	0,54	0,44
CNN Simples	+ Preproc coif4	0,6515	0,72	0,74	0,73	0,52	0,50	0,51
CNN Simples	+ Preproc coif4 + Aug	0,5455	0,80	0,38	0,52	0,43	0,83	0,57

- Acurácia aproximada de 52%; desempenho fraco na classe Anormal (precision 30%, recall 25%, f1 = 0,27).
- *Data augmentation* melhorou a classe Anormal ($f1 = 0,44$), mas reduziu a acurácia geral, indicando aumento de variabilidade.
- O pré-processamento *Coiflet* gerou um salto: acurácia 0,65 e $f1 = 0,51$ para Anormal.
- *Coiflet + augmentation* trouxe o melhor equilíbrio: *recall* da classe Anormal 0,83 e $f1 = 0,57$, apesar de queda na classe Normal.



Resultados – ResNet18

Arq.	Config.	Acc	P(N)	R(N)	F1(N)	P(A)	R(A)	F1(A)
ResNet18	Baseline	0,5606	0,64	0,71	0,67	0,37	0,29	0,33
ResNet18	+ Augmentation	0,5152	0,61	0,67	0,64	0,30	0,25	0,27
ResNet18	+ Preproc coif4	0,6212	0,67	0,81	0,73	0,47	0,29	0,36
ResNet18	+ Preproc coif4 + Aug	0,6364	0,72	0,69	0,71	0,50	0,54	0,52

- Sem pré-processamento: acurácia 0,56, f1 Normal 0,67 e f1 Anormal 0,33.
- Com *augmentation* isolada: acurácia 0,51; f1 Normal 0,64 e f1 Anormal 0,27. A variabilidade não ajudou sem pré-processamento.
- *Coiflet* isolado: acurácia 0,62; f1 Anormal subiu de 0,27 para 0,36.
- *Coiflet + augmentation*: um dos cenários mais equilibrados (acurácia 0,64; f1 Normal 0,71; f1 Anormal 0,52).



Resultados – ResNet34

Arq.	Config.	Acc	P(N)	R(N)	F1(N)	P(A)	R(A)	F1(A)
ResNet34	Baseline	0,6061	0,65	0,81	0,72	0,43	0,25	0,32
ResNet34	+ Augmentation	0,5000	0,60	0,64	0,62	0,29	0,25	0,27
ResNet34	+ Preproc coif4	0,6818	0,76	0,74	0,75	0,56	0,58	0,57
ResNet34	+ Preproc coif4 + Aug	0,5455	0,60	0,86	0,71	0,00	0,00	0,00

- Sem pré-processamento: acurácia 0,61; forte viés para Normal ($f1 = 0,72$); Anormal com $f1 = 0,32$.
- *Augmentation* isolada: queda acentuada (acurácia 0,50), aumentando ruído e instabilidade.
- *Coiflet* isolado: melhor cenário (acurácia 0,68; $f1$ Normal = 0,75; $f1$ Anormal = 0,57).
- *Coiflet + augmentation*: colapso total da classe Anormal ($f1 = 0$). A arquitetura é sensível ao excesso de variabilidade.



Resultados – ResNet50

Arq.	Config.	Acc	P(N)	R(N)	F1(N)	P(A)	R(A)	F1(A)
ResNet50	Baseline	0,5000	0,59	0,69	0,64	0,24	0,17	0,20
ResNet50	+ Augmentation	0,5758	0,62	0,88	0,73	0,17	0,04	0,07
ResNet50	+ Preproc coif4	0,6515	0,71	0,76	0,74	0,52	0,46	0,49
ResNet50	+ Preproc coif4 + Aug	0,6515	0,70	0,79	0,74	0,53	0,42	0,47

- Sem pré-processamento: acurácia 0,50; forte desequilíbrio entre as classes.
- *Augmentation* isolada: acurácia 0,58, mas f1 da classe Anormal = 0,07.
- *Coiflet* isolado: maior evolução (acurácia 0,65; f1 Normal = 0,74; f1 Anormal = 0,49).
- *Coiflet + augmentation*: desempenho estável (acurácia 0,65); ResNet50 tolerou melhor a variabilidade quando os dados já estavam limpos.



Conclusões

- O pré-processamento com Wavelet Coiflet foi o fator que mais contribuiu para o aumento de desempenho, equilibrando as classes e destacando estruturas relevantes.
- As arquiteturas ResNet apresentaram resultados superiores à CNN simples; a ResNet34 + Coiflet obteve o melhor desempenho geral.
- A qualidade das imagens de entrada teve impacto maior do que o uso isolado de data augmentation.
- A combinação Wavelet + augmentation mostrou sensibilidade dependendo da arquitetura, reforçando a importância de ajustes específicos para cada modelo.
- Conclui-se que estratégias adequadas de pré-processamento e redes mais profundas são essenciais para bases pequenas e desbalanceadas como a Mini-MIAS.



Contribuições Científicas

- Investigação do impacto do pré-processamento (transformada Wavelet + *data augmentation*) no desempenho de uma CNN aplicada à detecção de nódulos.
- Análise comparativa de diferentes arquiteturas ResNet (ResNet18, ResNet34 e ResNet50) sob múltiplos cenários experimentais.
- Proposição de um novo ponto de partida para configuração de CNNs, servindo como base para futuros ajustes de hiperparâmetros em estudos semelhantes.



- Integrar a Transformada Wavelet diretamente na pipeline da rede, por meio de camadas Wavelet-CNN treináveis.
- Avaliar o método em bases maiores e mais balanceadas para investigar a capacidade de generalização.
- Testar outras arquiteturas de CNN, como EfficientNet, VGG e AlexNet, ampliando a comparação entre modelos.



Referências

- Freitas, A. G. d., Kemp, C., Louveira, M. H., Fujiwara, S. M., & Campos, L. F. (2006). Mamografia Digital: Perspectiva Atual e Aplicações Futuras [Atualização]. *Radiologia Brasileira*, 39(4), 287–296. <https://doi.org/10.1590/S0100-39842006000400012>
- Martins, R. M., von Wangenheim, C. G., Rauber, M. F., Borgatto, A. F., & Hauck, J. C. R. (2024). Exploring the relationship between learning of machine learning concepts and socioeconomic status background among middle and high school students: a comparative analysis. *ACM Transactions on Computing Education*, 24(3), 1–31. <https://doi.org/10.1145/3680288>
- Rosa, A. A. d. (2025). Reconhecimento por imagem de lances de xadrez com visão computacional e redes neurais convolucionais. https://wiki.sj.ifsc.edu.br/images/a/a0/TCC_ANDREY_ADRIANO_DA_ROSA.pdf
- Silva Junior, E. C. d. (2022). Construção e análise de rede neural convolucional com neurônios pulsados para classificação de imagens [Dissertação de Mestrado]. Universidade de São Paulo, Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto.



Obrigada!

Dúvidas?

Jéssica Gomes Carrico
Trabalho de Conclusão de Curso

Engenharia de Telecomunicações – IFSC

jessica.c13@aluno.ifsc.edu.br
github.com/jessicac13/tcc

